

Aula 2.2: Variáveis Truncadas

Econometria I - IBMEC

Marcus L. Nascimento

19 de maio de 2026

1. Introdução

2. Estimação e Inferência

3. Interpretação dos Coeficientes

Introdução

Introdução

- Assim como nos casos em que $Y \in \mathbb{R}$ e $Y \in \{0, 1\}$, continuamos interessados em aprender sobre Y a partir de um conjunto de variáveis independentes $X_1, X_2, \dots, X_p$.
- Por conveniência, introduziremos uma notação vetorial, na qual

$$\mathbf{x} = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} \quad \text{e} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{bmatrix}.$$

Logo, $\mathbf{x}'\boldsymbol{\beta} = \beta_0 + x_1\beta_1 + x_2\beta_2 + \dots + x_p\beta_p$.

- Nesta etapa do curso, estudaremos o caso em que Y é essencialmente uma variável contínua não negativa que assume valores em zero com probabilidade positiva.
 - Renda oriunda do trabalho;
 - Número de horas trabalhadas;
 - Despesa com bebida alcoólica.

- No caso descrito anteriormente, o **modelo Tobit** é comumente aplicado. O modelo expressa a variável resposta em termos de uma variável latente:

$$\begin{aligned}y &= \max\{0, y^*\} \\ y^* &= \mathbf{x}'\boldsymbol{\beta} + \varepsilon \\ \varepsilon|\mathbf{x} &\sim N(0, \sigma^2).\end{aligned}$$

- $y = \max\{0, y^*\}$ implica que

$$y = \begin{cases} y^*, & \text{se } y^* \geq 0 \\ 0, & \text{se } y^* < 0. \end{cases}$$

- A variável latente y^* satisfaz as suposições do modelo linear clássico, em particular: distribuição normal e homocedástica com média condicional linear.

Estimação e Inferência

Estimação por Máxima Verossimilhança

- Para descrever a função de verossimilhança, iremos inicialmente descrever a densidade da variável resposta condicional nas variáveis independentes separando em dois casos:

- $Y > 0$:

$$\begin{aligned}f(y|\mathbf{x}) &= (2\pi\sigma^2)^{-1/2}\exp\left\{-\frac{(y - \mathbf{x}'\boldsymbol{\beta})^2}{2\sigma^2}\right\} \\&= \sigma^{-1}\phi\left(\frac{y - \mathbf{x}'\boldsymbol{\beta}}{\sigma}\right).\end{aligned}$$

- $Y = 0$:

$$\begin{aligned}P(Y = 0|\mathbf{x}) &= P(Y^* < 0|\mathbf{x}) \\&= P(\varepsilon < -(\mathbf{x}'\boldsymbol{\beta})|\mathbf{x}) \\&= P(\varepsilon/\sigma < -(\mathbf{x}'\boldsymbol{\beta})/\sigma|\mathbf{x}) \\&= \Phi(-(\mathbf{x}'\boldsymbol{\beta})/\sigma) \\&= 1 - \Phi((\mathbf{x}'\boldsymbol{\beta})/\sigma).\end{aligned}$$

Estimação por Máxima Verossimilhança

Supondo $(y_i, x_{i1}, \dots, x_{ip})$ uma amostra aleatória da população, temos que a função densidade condicional é dada por:

$$f(y_i | \mathbf{x}_i) = [1 - \Phi((\mathbf{x}'_i \boldsymbol{\beta}) / \sigma)]^{1(y_i=0)} \times \left[\sigma^{-1} \phi \left(\frac{y_i - \mathbf{x}'_i \boldsymbol{\beta}}{\sigma} \right) \right]^{1(y_i>0)}.$$

A função **log-verossimilhança**, por sua vez, é dada por:

$$\ell_i(\boldsymbol{\beta}, \sigma) = 1(y_i = 0) \cdot \ln[1 - \Phi((\mathbf{x}'_i \boldsymbol{\beta}) / \sigma)] + 1(y_i > 0) \cdot \ln \left[\sigma^{-1} \phi \left(\frac{y_i - \mathbf{x}'_i \boldsymbol{\beta}}{\sigma} \right) \right].$$

Estimação por Máxima Verossimilhança

Considerando uma amostra aleatória de tamanho n , a função **log-verossimilhança** é obtida ao tomarmos a soma em i , $i = 1, 2, \dots, n$:

$$\begin{aligned}\ell(\boldsymbol{\beta}, \sigma) &= \sum_{i=1}^n \ell_i(\boldsymbol{\beta}, \sigma) \\ &= \sum_{i=1}^n \left\{ 1(y_i = 0) \cdot \ln[1 - \Phi((\mathbf{x}_i' \boldsymbol{\beta})/\sigma)] + 1(y_i > 0) \cdot \ln \left[\sigma^{-1} \phi \left(\frac{y_i - \mathbf{x}_i' \boldsymbol{\beta}}{\sigma} \right) \right] \right\}.\end{aligned}$$

O estimador de máxima verossimilhança de β_j , $j = 0, 1, \dots, p$, denotado por $\hat{\beta}_j$, é obtido através da maximização da log-verossimilhança.

Estimação por Máxima Verossimilhança

OBSERVAÇÕES:

- Assim como nos casos logit e probit, não é possível obter fórmulas fechadas para os estimadores do modelo tobit.
 - Métodos numéricos são aplicados para encontrar as soluções do problema.
- Vale recordar também que sob condições bastante gerais, o estimador de máxima verossimilhança é
 - Consistente;
 - Assintoticamente normal;
 - Assintoticamente eficiente.
- A partir dos resultados de normalidade assintótica, é possível testar a hipótese $H_0 : \beta_j = 0$ de maneira usual utilizando uma estatística $t \hat{\beta}_j / \text{se}(\hat{\beta}_j)$.

Teste de Razão de Verossimilhança

- Nos casos em que desejamos testar hipóteses acerca de um grupo de variáveis:

$$H_0 : \beta_{p-q+1} = \beta_{p-q+2} = \dots = \beta_p = 0$$

$$H_1 : H_0 \text{ não é verdadeira,}$$

onde $q < p$ é o tamanho do grupo a ser testado, podemos aplicar o teste da razão de verossimilhanças.

- Como vimos, a estatística de razão de verossimilhança é dada por:

$$LR = 2[\ell_{ur} - \ell_r]$$

onde ℓ_{ur} é o valor da log-verossimilhança para o modelo irrestrito e ℓ_r é o valor da log-verossimilhança para o modelo restrito.

- LR possui aproximadamente uma distribuição χ^2_q .

Interpretação dos Coeficientes

Valor Esperado (Condicional e Incondicional)

- É importante observar que β_j mede o efeito parcial de X_j em $E(Y^*|\mathbf{X} = \mathbf{x})$, onde Y^* é a variável latente.
- Estamos interessados, no entanto, em explicar a variável Y e precisamos caracterizar o valor esperado de Y como função de $X_1, X_2, \dots, X_p$.

$$\begin{aligned} E(Y|\mathbf{X} = \mathbf{x}) &= P(Y = 0|\mathbf{X} = \mathbf{x})E(Y|Y = 0, \mathbf{X} = \mathbf{x}) \\ &+ P(Y > 0|\mathbf{X} = \mathbf{x})E(Y|Y > 0, \mathbf{X} = \mathbf{x}) \\ &= P(Y > 0|\mathbf{X} = \mathbf{x})E(Y|Y > 0, \mathbf{X} = \mathbf{x}) \\ &= \Phi((\mathbf{x}'\beta)/\sigma)E(Y|Y > 0, \mathbf{X} = \mathbf{x}). \end{aligned}$$

- A partir da equação acima, notamos que para caracterizar $E(Y|\mathbf{X} = \mathbf{x})$ é necessário descrever $E(Y|Y > 0, \mathbf{X} = \mathbf{x})$.

Valor Esperado (Condicional e Incondicional)

Para obter $E(Y|Y > 0, \mathbf{X} = \mathbf{x})$, aplicamos o seguinte resultado para variáveis aleatórias com distribuição normal: Se $Z \sim N(0, 1)$, então $E(Z|Z > c) = \phi(c)/[1 - \Phi(c)]$ para qualquer constante c .

$$\begin{aligned} E(Y|Y > 0, \mathbf{X} = \mathbf{x}) &= \mathbf{x}'\boldsymbol{\beta} + E(\varepsilon|\varepsilon > -(\mathbf{x}'\boldsymbol{\beta})) \\ &= \mathbf{x}'\boldsymbol{\beta} + \sigma E(\varepsilon/\sigma|\varepsilon/\sigma > -(\mathbf{x}'\boldsymbol{\beta})/\sigma) \\ &= \mathbf{x}'\boldsymbol{\beta} + \sigma\phi((\mathbf{x}'\boldsymbol{\beta})/\sigma)/\Phi((\mathbf{x}'\boldsymbol{\beta})/\sigma), \end{aligned}$$

já que $\phi(-c) = \phi(c)$, $1 - \Phi(-c) = \Phi(c)$ e ε/σ possui uma distribuição normal padrão independente de $X_1, \dots, X_p$.

Valor Esperado (Condicional e Incondicional)

Em resumo, temos que

$$E(Y|Y > 0, \mathbf{X} = \mathbf{x}) = \mathbf{x}'\boldsymbol{\beta} + \sigma\lambda((\mathbf{x}'\boldsymbol{\beta})/\sigma),$$

onde $\lambda(c) = \phi(c)/\Phi(c)$ é denominada razão de Mills inversa.

OBSERVAÇÕES:

- O valor esperado condicional em $Y > 0$ é $\mathbf{x}'\boldsymbol{\beta}$ mais um termo estritamente positivo;
- É possível visualizar por que utilizar o OLS para as observações $y_i > 0$, $i = 1, \dots, n$, nem sempre estimará $\beta_1, \beta_2, \dots, \beta_p$.
 - A razão de Mills inversa é uma variável omitida, geralmente correlacionada com elementos de $X_1, \dots, X_p$.

Valor Esperado (Condicional e Incondicional)

Por fim, a partir de $E(Y|Y > 0, \mathbf{X} = \mathbf{x})$, conseguimos caracterizar $E(Y|\mathbf{X} = \mathbf{x})$:

$$\begin{aligned} E(Y|\mathbf{X} = \mathbf{x}) &= \Phi((\mathbf{x}'\boldsymbol{\beta})/\sigma) \times [\mathbf{x}'\boldsymbol{\beta} + \sigma\lambda((\mathbf{x}'\boldsymbol{\beta})/\sigma)] \\ &= \Phi((\mathbf{x}'\boldsymbol{\beta})/\sigma)(\mathbf{x}'\boldsymbol{\beta}) + \sigma\phi((\mathbf{x}'\boldsymbol{\beta})/\sigma). \end{aligned}$$

OBSERVAÇÕES:

- $E(Y|\mathbf{X} = \mathbf{x})$ é uma função não linear de $x_1, \dots, x_p$ e $\beta_0, \beta_1, \dots, \beta_p$;
- Pode ser demonstrado que a parcela direita da igualdade é positiva para quaisquer valores de $x_1, \dots, x_p$ e $\beta_0, \beta_1, \dots, \beta_p$.
 - Para quaisquer valores de $x_1, \dots, x_p$ e $\beta_0, \beta_1, \dots, \beta_p$, $E(Y|\mathbf{X} = \mathbf{x})$ é positivo.

Efeitos Parciais

Suponha X_j uma variável contínua e suponha que X_j não está funcionalmente relacionada às demais variáveis independentes. Os efeitos parciais de X_j sobre Y são calculados da seguinte forma:

$$\begin{aligned}\frac{\partial E(Y|\mathbf{X} = \mathbf{x})}{\partial x_j} &= \frac{\partial P(Y > 0|\mathbf{X} = \mathbf{x})}{\partial x_j} \cdot E(Y|Y > 0, \mathbf{X} = \mathbf{x}) \\ &+ P(Y > 0|\mathbf{X} = \mathbf{x}) \cdot \frac{\partial E(Y|Y > 0, \mathbf{X} = \mathbf{x})}{\partial x_j}.\end{aligned}$$

Como $P(Y > 0|\mathbf{X} = \mathbf{x}) = \Phi((\mathbf{x}'\boldsymbol{\beta})/\sigma)$,

$$\frac{\partial P(Y > 0|\mathbf{X} = \mathbf{x})}{\partial x_j} = (\beta_j/\sigma)\phi((\mathbf{x}'\boldsymbol{\beta})/\sigma).$$

Utilizando $d\Phi/dc = \phi(c)$ e $d\phi/dc = -c\phi(c)$, é possível mostrar que $d\lambda/dc = -\lambda(c)[c + \lambda(c)]$. Desta forma,

$$\begin{aligned}\frac{\partial E(Y|Y > 0, \mathbf{X} = \mathbf{x})}{\partial x_j} &= \beta_j - \sigma \frac{\beta_j}{\sigma} \times \frac{\lambda((\mathbf{x}'\boldsymbol{\beta})/\sigma)}{(\mathbf{x}'\boldsymbol{\beta})/\sigma + \lambda((\mathbf{x}'\boldsymbol{\beta})/\sigma)} \\ &= \beta_j \times \left[1 - \frac{\lambda((\mathbf{x}'\boldsymbol{\beta})/\sigma)}{(\mathbf{x}'\boldsymbol{\beta})/\sigma + \lambda((\mathbf{x}'\boldsymbol{\beta})/\sigma)} \right]\end{aligned}$$

Efeitos Parciais

Caracterizando $\partial P(Y|\mathbf{X} = \mathbf{x})/\partial x_j$ e $\partial E(Y|Y > 0, \mathbf{X} = \mathbf{x})/\partial x_j$, temos

$$\frac{\partial E(Y|\mathbf{X} = \mathbf{x})}{\partial x_j} = \beta_j \Phi((\mathbf{x}'\boldsymbol{\beta})/\sigma).$$

Na prática, podemos calcular os efeitos parciais considerando duas abordagens:

- Efeito parcial na média (PEA):

$$\hat{\beta}_j \Phi((\hat{\beta}_0 + \hat{\beta}_1 \bar{x}_1 + \dots + \hat{\beta}_p \bar{x}_p)/\hat{\sigma}).$$

- Efeito parcial médio (APE):

$$n^{-1} \hat{\beta}_j \sum_{i=1}^n \Phi((\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \dots + \hat{\beta}_p x_{ip})/\hat{\sigma}).$$