

# Parte 1.1: Regressão Linear Simples e Mínimos Quadrados Ordinários

Econometria I - IBMEC

Marcus L. Nascimento

26 de agosto de 2025

1. Regressão Linear Simples
2. Mínimos Quadrados Ordinários (MQO)
3. Coeficiente de determinação ( $R^2$ )
4. Formas funcionais

## Regressão Linear Simples

- A análise de regressão estuda a relação entre o que denominamos **variável dependente** ou **variável resposta** e um conjunto de variáveis que denominamos **variáveis independentes**, **explicativas** ou **regressores**.
  - **Variável dependente**: Variável que está sendo estudada, comumente denotada por  $Y$ ;
  - **Variáveis independentes**: Variáveis utilizadas para explicar a variável dependente, comumente denotadas por  $X_1, X_2, \dots, X_p$ .
- A relação entre as variáveis é representada por um modelo matemático, que associa a variável dependente com as variáveis independentes.
- Este modelo é designado por **Regressão Linear Simples** quando há uma variável explicativa ( $p = 1$ ) e uma variável resposta.
- Analogamente, quando o modelo envolve duas ou mais variáveis explicativas passamos a denominá-lo **Regressão Linear Múltipla**.

# Introdução

Através de modelos de Regressão Linear Simples, estudamos a relação linear entre duas variáveis quantitativas.

EXEMPLOS:

- Renda semanal e despesas de consumo;
- Variação dos salários e taxa de desemprego;
- Vendas de produtos e investimentos em publicidade.


CORRELAÇÃO VS. REGRESSÃO:

- Regressão explicita a forma como variáveis estão relacionadas;
- Correlação quantifica a força ou grau com que variáveis estão relacionadas.


# Diagrama de dispersão

Diagramas de dispersão permitem decidir empiricamente se há uma relação linear entre uma variável dependente ( $Y$ ) e uma variável explicativa ( $X$ ).


A) Correlação linear negativa




B) Correlação linear positiva




C) Sem correlação



D) Padrão não linear



E) Padrão não linear



# Definição

Um modelo de Regressão Linear simples é descrito da seguinte forma:

$$Y = E(Y|X = x) + \varepsilon = \beta_0 + \beta_1 x + \varepsilon,$$

onde:

- A função  $E(Y|X = x)$  é chamada regressão de  $Y$  em  $X$ ;
- $Y$ : variável dependente;
- $X$ : variável explicativa ou independente medida sem erro (não aleatória);
- $\beta_0$ : coeficiente de regressão que representa o intercepto (parâmetro desconhecido do modelo);
- $\beta_1$ : coeficiente de regressão que representa a inclinação (parâmetro desconhecido do modelo);
- $\varepsilon$ : erro aleatório que contém a variação de  $Y$  que não pode ser explicada linearmente pelo comportamento da variável  $X$ .

# Suposições do modelo

Dadas  $n$  observações do par  $X$  e  $Y$ ,  $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ , temos:

$$Y_i = E(Y_i|X = x_i) + \varepsilon_i = \beta_0 + \beta_1 x_i + \varepsilon_i.$$

SUPOSIÇÕES SOBRE OS ERROS ( $\varepsilon_i$ ):

- Independência:  $\varepsilon_i$ 's são variáveis aleatórias independentes;
- $\text{Var}(\varepsilon_i|x_i) = \text{Var}(\varepsilon_i) = \sigma^2$ ;
- $E(\varepsilon_i|x_i) = E(\varepsilon_i) = 0$ .

A partir das suposições, temos:

$$E(Y_i|X = x_i) = \beta_0 + \beta_1 x_i \text{ e } \text{Var}(Y_i|X = x_i) = \sigma^2.$$



Vale ressaltar que o termo regressão linear significa regressão linear nos **parâmetros**.

PERGUNTAS:

- $y_i = \beta_0 + \beta_1 x_i^2 + \varepsilon_i$  é considerado um modelo de regressão linear simples?

Vale ressaltar que o termo regressão linear significa regressão linear nos **parâmetros**.

PERGUNTAS:

- $y_i = \beta_0 + \beta_1 x_i^2 + \varepsilon_i$  é considerado um modelo de regressão linear simples?
- E  $\ln(y_i) = \beta_0 + \beta_1 \ln(x_i) + \varepsilon_i$ ?

## Exercícios (Wooldridge, J. M. (2003))

Suponha que  $Y$  denote o número de filhos e  $X$  seja a escolaridade medida em anos de uma mulher. Um modelo simples relacionando fertilidade com escolaridade é

$$y = \beta_0 + \beta_1 x + \varepsilon,$$

onde  $\varepsilon$  é o erro não observado.

## Exercícios (Wooldridge, J. M. (2003))

Suponha que  $Y$  denote o número de filhos e  $X$  seja a escolaridade medida em anos de uma mulher. Um modelo simples relacionando fertilidade com escolaridade é

$$y = \beta_0 + \beta_1 x + \varepsilon,$$

onde  $\varepsilon$  é o erro não observado.

(i) Quais fatores estão contidos em  $\varepsilon$ ? É provável que eles estejam correlacionados com a escolaridade?

## Exercícios (Wooldridge, J. M. (2003))

Suponha que  $Y$  denote o número de filhos e  $X$  seja a escolaridade medida em anos de uma mulher. Um modelo simples relacionando fertilidade com escolaridade é

$$y = \beta_0 + \beta_1 x + \varepsilon,$$

onde  $\varepsilon$  é o erro não observado.

- (i) Quais fatores estão contidos em  $\varepsilon$ ? É provável que eles estejam correlacionados com a escolaridade?
- (ii) A relação entre a escolaridade e os fatores contidos em  $\varepsilon$  impacta alguma das suposições do modelo de regressão linear simples? Explique.

## Exercícios (Wooldridge, J. M. (2003))

Em um modelo de regressão linear simples,  $y = \beta_0 + \beta_1 x + \varepsilon$ , suponha que  $E(\varepsilon) \neq 0$ . Sendo  $E(\varepsilon) = \alpha_0$ , mostre que o modelo pode ser sempre reescrito com a mesma inclinação ( $\beta_1$ ), porém com novo intercepto e novo erro, onde o novo erro possui valor esperado igual a zero.

## Mínimos Quadrados Ordinários (MQO)

Dado um modelo de regressão linear simples, como estimamos os parâmetros  $\beta_0$  e  $\beta_1$ ?



Dado um modelo de regressão linear simples, como estimamos os parâmetros  $\beta_0$  e  $\beta_1$ ?

Mínimos Quadrados Ordinários (MQO): procedimento bastante utilizado em Econometria para obtenção de estimadores.

- Quanto menor for o erro quadrático total ,  $\sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$ , melhor será a estimativa;
- Desejamos **minimizar** o erro quadrático total;
- Minimizar o erro quadrático total significará encontrar valores de  $\beta_0$  e  $\beta_1$  que minimizem a função

$$S(\beta_0, \beta_1) = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2.$$

# Estimadores de Mínimos Quadrados Ordinários

O mínimo de  $S(\beta_0, \beta_1)$  é obtido através do cálculo de sua derivada com respeito a  $\beta_0$  e  $\beta_1$ , igualando o resultado a zero.

$$\frac{\partial S(\beta_0, \beta_1)}{\partial \beta_0} = 0; \quad (1)$$

$$\frac{\partial S(\beta_0, \beta_1)}{\partial \beta_1} = 0. \quad (2)$$

A partir de (1) e (2), obtemos:

$$\begin{aligned} \hat{\beta}_0 &= \bar{y} - \hat{\beta}_1 \bar{x}; \\ \hat{\beta}_1 &= \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}, \end{aligned}$$

onde  $\bar{x} = \sum_{i=1}^n x_i / n$  e  $\bar{y} = \sum_{i=1}^n y_i / n$ .

# Estimadores de Mínimos Quadrados Ordinários

Definindo

$$S_{xy} = \sum_{i=1}^n x_i y_i - n\bar{x}\bar{y};$$

$$S_{xx} = \sum_{i=1}^n x_i^2 - n\bar{x}^2;$$

$$S_{yy} = \sum_{i=1}^n y_i^2 - n\bar{y}^2,$$

reescrevemos  $\hat{\beta}_0$  e  $\hat{\beta}_1$  da seguinte forma:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x};$$

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}.$$

Seja  $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$  a **reta de regressão estimada**, temos:

- $x = 0$ :  $\hat{y} = \hat{\beta}_0$ .

$\hat{\beta}_0$  é o ponto onde a reta corta o eixo das ordenadas e pode ser interpretável ou não.

- $x \rightarrow x + 1$ :  $\Delta \hat{y} = [\hat{\beta}_0 + \hat{\beta}_1(x + 1)] - [\hat{\beta}_0 + \hat{\beta}_1 x] = \hat{\beta}_1$ .

$\hat{\beta}_1$  é o coeficiente angular e representa o quanto varia a média de  $Y$  para um aumento de uma unidade da variável  $X$ .

- A1. (Linearidade) No modelo populacional, a variável resposta  $y$  está relacionada a variável independente  $x$  e ao erro  $\varepsilon$  da seguinte forma:

$$y = \beta_0 + \beta_1 x + \varepsilon,$$

onde  $\beta_0$  e  $\beta_1$  são os parâmetros populacionais para o intercepto e a inclinação.

- A2. (Amostragem aleatória) Pode-se utilizar uma amostra aleatória de tamanho  $n$ ,  $\{(x_i, y_i) : i = 1, 2, \dots, n\}$ , do modelo populacional.
- A3. (Média Condicional Zero)  $E(\varepsilon|x) = 0$ .

A4. (Variação amostral no regressor) Na amostra, as variáveis independentes  $x_i$ ,  $i = 1, 2, \dots, n$ , não são todas iguais a mesma constante.

A5. (Homocedasticidade)  $\text{Var}(\varepsilon|x) = \sigma^2$ .

OBSERVAÇÃO:

- $E(\varepsilon|x) = 0$  implica que todos os fatores contidos no erro devem ser não correlacionados com o regressor.

- Sob as suposições A1-A4, os estimadores de Mínimos Quadrados Ordinários  $\hat{\beta}_0$  e  $\hat{\beta}_1$  são não viesados:

$$E(\hat{\beta}_0) = \beta_0 \text{ e } E(\hat{\beta}_1) = \beta_1.$$

- Sob as suposições A1-A5, as variâncias dos estimadores de Mínimos Quadrados Ordinários dependem da dispersão da variável independente e da variância do erro:

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left( \frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right) \text{ e } \text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

- $\text{Var}(\hat{\beta}_1) \xrightarrow{n \rightarrow \infty} 0$  para valores de  $x_i$  distribuídos ao redor da média  $\bar{x}$ ;
- $\text{Var}(\hat{\beta}_0) \xrightarrow{n \rightarrow \infty} 0$  assumindo que os valores de  $x_i$  são apropriadamente selecionados (não clusterizados próximos a média).

Melhores estimadores lineares não-viesados (BLUE):

- Os estimadores de MQO para os parâmetros  $\beta_0$  e  $\beta_1$  são os melhores dentre todos os estimadores da classe dos lineares não-viesados;
- Além de serem não-viesados, apresentam a menor variância dentre os demais estimadores não-viesados, gerando estimadores com menor erro quadrático médio dentre os lineares.



## Estimador para a variância do erro ( $\sigma^2$ )

Seja  $e_i = y_i - \hat{y}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$  o **resíduo** da regressão linear. Para obtermos um estimador não enviesado de  $\sigma^2$ , analisamos a dispersão em torno da reta de regressão estimada:

$$SSR = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \text{ (Soma de quadrados dos resíduos) .}$$

Sob as suposições A1-A5,  $E(\sum_{i=1}^n e_i^2) = (n-2)\sigma^2$ , logo um estimador não viesado de  $\sigma^2$  é

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n e_i^2}{n-2} = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n-2}.$$

## Cálculo das variâncias dos estimadores de MQO

Com base em uma amostra, é possível encontrar estimativas para as variâncias de  $\hat{\beta}_0$  e  $\hat{\beta}_1$  substituindo  $\sigma^2$  por  $\hat{\sigma}^2$  (estimador não viesado para  $\sigma^2$ ) nas expressões para  $\text{Var}(\hat{\beta}_0)$  e  $\text{Var}(\hat{\beta}_1)$ :

$$\widehat{\text{Var}}(\hat{\beta}_0) = \hat{\sigma}^2 \left( \frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right) \text{ e } \widehat{\text{Var}}(\hat{\beta}_1) = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (x_i - \bar{x})^2},$$

para os quais

$$E(\widehat{\text{Var}}(\hat{\beta}_0)) = \text{Var}(\hat{\beta}_0) \text{ e } E(\widehat{\text{Var}}(\hat{\beta}_1)) = \text{Var}(\hat{\beta}_1).$$


Coeficiente de determinação ( $R^2$ )

Uma vez obtida a **reta de regressão estimada**, faz-se necessário construir uma medida que indique, mesmo que de modo imperfeito, a qualidade do ajuste do modelo de regressão.

Para tal, definiremos as seguintes quantidades:

- $y - \bar{y}$ : erro ao se prever  $y$  pela média geral;
- $y - \hat{y}$ : erro ao se prever  $y$  pelo valor estimado para  $E(Y|X)$  (**resíduo**);
- $\hat{y} - \bar{y}$ : “ganho” ao se prever  $y$  pelo valor estimado para  $E(Y|X)$  em comparação ao se prever  $y$  pela média geral  $\bar{y}$ .

# Definição



A partir das quantidades definidas anteriormente, escrevemos suas respectivas somas de quadrados:

- Soma de quadrados total (SST):  $SST = \sum_{i=1}^n (y_i - \bar{y})^2$ ;
- Soma de quadrados dos resíduos (SSR):  $SSR = \sum_{i=1}^n (y_i - \hat{y}_i)^2$ ;
- Soma de quadrados devido à explicação (SSE):  $SSE = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$ .

RESULTADO:  $SST = SSE + SSR$ ,

onde:

- SSE: parcela da variabilidade de  $y$  que é explicada pelos regressores do modelo;
- SSR: parcela da variabilidade de  $y$  que **não** é explicada pelos regressores do modelo.

Por fim, o Coeficiente de Determinação ( $R^2$ ) é expresso da seguinte forma:

$$R^2 = \frac{SSE}{SST} = 1 - \frac{SSR}{SST}.$$

# Interpretação

- Como  $R^2$  é uma proporção, sempre será um número entre 0 e 1;
- $R^2 = 0$ : indica que o modelo não explica nada da variação da variável resposta ao redor da média. A média da variável dependente prediz a mesma tão bem quanto o modelo de regressão;
- $R^2 = 1$ : indica que o modelo explica toda a variação da variável resposta no entorno da média;
- $100 \times R^2$  pode ser interpretado como a **proporção da variabilidade total de  $y$  que é explicada pelo regressor do modelo adotado**



## Exercícios (Wooldridge, J. M. (2003))

Em um conjunto de dados com registros de nascimentos nos Estados Unidos, duas variáveis de interesse são o peso do bebê ao nascer (bwght) e o número médio de cigarros que a mãe fumou por dia durante a gestação (cigs).

A regressão linear simples a seguir foi estimada utilizando  $n = 1388$  nascimentos:

$$\widehat{\text{bwght}} = \hat{\beta}_0 + \hat{\beta}_1 \text{cigs},$$

onde  $\hat{\beta}_0 = 110,77$  e  $\hat{\beta}_1 = -0.514$

(i) Qual o valor predito para o peso ao nascer quando  $\text{cigs} = 0$ ? Qual valor predito quando  $\text{cigs} = 20$ ? Comente sobre a diferença.

(ii) O modelo de regressão linear simples necessariamente captura uma relação causal entre o peso do bebê ao nascer e o hábito de fumar da mãe? Explique.

## Exercícios (Wooldridge, J. M. (2003))

Considerando uma função de consumo linear

$$\widehat{\text{cons}} = \hat{\beta}_0 + \hat{\beta}_1 \text{inc},$$

a propensão marginal a consumir (estimada) é dada pela inclinação  $\hat{\beta}_1$ , enquanto a propensão média a consumir é dada por  $\widehat{\text{cons}}/\text{inc} = \hat{\beta}_0/\text{inc} + \hat{\beta}_1$ .

Utilizando dados sobre a renda anual e o consumo de 100 famílias, a seguinte equação é obtida:

$$\widehat{\text{cons}} = \hat{\beta}_0 + \hat{\beta}_1 \text{inc},$$

onde  $\hat{\beta}_0 = -124,84$  e  $\hat{\beta}_1 = 0.853$

- (i) Interprete o intercepto na equação anterior e comente sobre seu sinal e magnitude.
- (ii) Qual é o consumo predito para uma família com renda de \$30.000?

## Formas funcionais

- Em muitas aplicações econômicas, a relação entre as variáveis dependente e independente não é adequadamente descrita através de um modelo linear.
- Há formas de considerar não-linearidades em modelos de regressão linear simples através da apropriada definição das variáveis dependente e independente.
- Em análise de regressão linear, estudamos modelos lineares nos parâmetros e vimos casos em que os modelos podem ou não ser lineares nas variáveis.
- As variáveis podem se tornar lineares através de transformações apropriadas: a relação não-linear pode ser “linearizável” por transformações.

- Em alguns casos, será possível fazer interpretações dos parâmetros em termos do problema de interesse ao se considerar a não-linearidade.
- **Efeito Marginal:** Mede o efeito da variável  $X$  na variável  $Y$ .

$$\frac{dY}{dX}.$$

- **Elasticidade:** Mede a variação percentual de  $Y$  correspondente a uma dada variação percentual em  $X$ .


$$\frac{\% \Delta E(Y|X)}{\% \Delta X} = \frac{dY}{dX} \times \frac{X}{Y},$$

$$\text{onde } \% \Delta X = 100 \cdot \frac{x - x_0}{x_0} = 100 \cdot \frac{\Delta x}{x_0}.$$

# Modelo Log-Log

**Forma funcional:**  $\ln(y) = \beta_0 + \beta_1 \ln(x) + \varepsilon$ .

**Figura:** Para análise do gráfico, considere que  $\beta_1 = b$ .



**Interpretação associada a  $\beta_1$ :**

$$\frac{\% \Delta E(Y|X)}{\% \Delta X} = \beta_1 \text{ (elasticidade).}$$

OBSERVAÇÕES:

- Modelo de elasticidade constante.
- O Modelo Log-Log decorre do fato de que o logaritmo aparece em ambos os membros da equação.
- Para utilizarmos esse modelo, todos os valores de  $Y$  e  $X$  devem ser positivos.

## EXEMPLO:

Podemos estimar um modelo de elasticidade constante relacionando os salários de diretores de empresas e as vendas relacionadas às companhias:

$$\ln(\text{salário}) = \beta_0 + \beta_1 \ln(\text{vendas}) + \varepsilon,$$

onde as vendas representam o total anual medido em milhões de dólares.

Suponha que o seguinte resultado é obtido ao estimarmos a equação anterior via MQO:

$$\ln(\text{salário}) = 4.822 + 0.257 \ln(\text{vendas}) + \varepsilon.$$

Qual interpretação é dada para  $\hat{\beta}_1 = 0.257$ ?



# Modelo Log-Nível

**Forma funcional:**  $\ln(y) = \beta_0 + \beta_1 x + \varepsilon$ .

**Interpretação associada a  $\beta_1$ :**

$$\frac{\% \Delta E(Y|X)}{\Delta X} = 100 \times \beta_1 \text{ (semi-elasticidade).}$$

EXEMPLO:

Considere o caso em que deseja-se estimar a relação entre salário e educação. Utilizando o salário na escala logarítmica, temos a seguinte equação:

$$\ln(\text{salário}) = \beta_0 + \beta_1 \text{educ} + \varepsilon,$$

onde a educação é medida em anos.

Suponha que ao estimarmos a equação anterior via MQO, obtemos  $\hat{\beta}_0 = 0.584$  e  $\hat{\beta}_1 = 0.083$ . Qual interpretação é dada para  $\hat{\beta}_1 = 0.083$ ?

# Modelo Log-Nível

A partir da equação  $\ln(y) = \beta_0 + \beta_1 x + \varepsilon$ , é possível observar que

$$y = e^{\beta_0 + \beta_1 x + \varepsilon}.$$

Logo,

$$\frac{dy}{dx} = \beta_1 e^{\beta_0 + \beta_1 x + \varepsilon} = \beta_1 y. \quad (3)$$

Reescrevendo (3), temos que

$$\beta_1 = \frac{dy/y}{dx},$$

ou seja,  $\beta_1$  representa uma **taxa de crescimento**. Dessa forma,  $\beta_1 = 0,04$  indica um crescimento de 4% em Y diante de uma variação de uma unidade em X.

**Forma funcional:**  $y = \beta_0 + \beta_1 \ln(x) + \varepsilon$ .

**Interpretação associada a  $\beta_1$ :**

$$\frac{\Delta E(Y|X)}{\% \Delta X} = \frac{\beta_1}{100}.$$

Neste caso, um aumento de 1% na variável independente  $X$  resulta em um aumento de  $\beta_1/100$  na variável dependente  $Y$ .

Model	Dependent Variable	Independent Variable	Interpretation of $\beta_1$
level-level	$y$	$x$	$\Delta y = \beta_1 \Delta x$
level-log	$y$	$\log(x)$	$\Delta y = (\beta_1/100)\% \Delta x$
log-level	$\log(y)$	$x$	$\% \Delta y = (100\beta_1) \Delta x$
log-log	$\log(y)$	$\log(x)$	$\% \Delta y = \beta_1 \% \Delta x$